

Eliminação de colunas

Olá! Neste vídeo, iremos verificar uma das abordagens de pré-processamento de dados quando existem dados faltantes em nosso conjunto.

Quando existem dados faltantes em algumas colunas, podemos utilizar a estratégia de imputar dados. Porém, a estratégia de imputar dados pode se mostrar ineficiente quando há muitos dados faltantes no nosso conjunto.

Ou seja, supondo que metade dos dados, em uma certa coluna, estejam faltando, não podemos confiar na média obtida uma vez que é uma quantidade de dados faltando que é bem considerável para o nosso conjunto.

Assim, essa média pode não refletir o padrão desses dados. Então, em alguns casos, quando o volume de valores faltantes por coluna é grande, podemos utilizar uma abordagem de eliminar a coluna.

Ou seja, uma vez que alguns dados estão faltando e esta coluna pode ficar descaracterizada,

podemos utilizar uma estratégia de apagar esta coluna uma vez que ela não terá um valor que possa contribuir para este nosso conjunto de dados.

Para trabalhar com esta abordagem, iremos carregar novamente nosso conjunto de dados utilizando a célula da seguinte maneira:

```
data = pd.read_table(fruit_data_with_colors_miss, na_values=[.,?])
```

usaremos "data", que será a variável que armazenará nosso conjunto de dados. "pd.read_table" a função que estamos utilizando para ler o nosso conjunto de dados. "(fruit_data_with_colors_miss.txt)" essa string indica o nosso conjunto de dados após essa string, vírgula para inserir o segundo parâmetro da função "read_table". Iremos utilizar "na_values=", onde teremos o ponto final como primeiro elemento (uma string com ponto final), e o segundo elemento da lista é o ponto de interrogação. Após a definição dessa lista, fecharemos o parêntese da "read_table".

Dessa maneira, efetuando a execução desta linha teremos os dados novamente carregados

a partir do arquivo.

E, executando a leitura deste conjunto de dados teremos o conjunto de dados com alguns dados faltantes.

Primeiramente, iremos calcular o nosso total de dados. O nosso total de dados é dado pela seguinte linha: "data.shape[]" e iremos verificar apenas o índice "0]" e o

resultado do "shape", que é o número de linhas e o número de colunas desse conjunto é "59".

Logo, temos que nosso total de dados são 59 dados.

Na linha seguinte, iremos verificar qual é a quantidade de dados faltantes em cada uma das colunas. Podemos efetuar esta verificação utilizando uma linha de uma maneira bem simples,

e ela é descrita da seguinte maneira: `data.isnull().sum()`

Ao executar esta linha, teremos como resultado o nome de todas as colunas do nosso conjunto de dados e as quantidades de dados faltantes em cada uma destas colunas.

Aqui, temos que a maioria das colunas para o conjunto de dados de frutas teve resultado igual a 0, porém as colunas "fruit_subtype", "mass" e "height", ou seja, o subtipo, a massa e a altura tiveram um valor faltante.

Então, dessa maneira, temos o valor total de dados faltantes e o valor total do conjunto de dados, entre faltantes e não-faltantes.

Dessa maneira, teremos duas abordagens: se a porcentagem de dados faltantes for superior a 25% nós devemos eliminar a coluna.

Se ela for inferior a 25%, podemos manter a coluna e utilizar uma das técnicas de imputação

vistas no vídeo anterior.

Então, dessa maneira, temos que 25% dos dados é o nosso limiar para eliminar ou não uma coluna.

Porém, alguns acreditam que 25% ainda é um valor considerável diante do conjunto de dados.

Então, existe outra abordagem, que é trabalhar com 10%.

A partir de 10% de dados faltantes, a coluna deve ser eliminada.

Esta é uma abordagem mais cética que vai ser mais criteriosa com o conjunto de dados.

A outra abordagem é mais permissiva uma vez que ela permite que tenhamos um conjunto maior de dados faltantes. Então, para calcular a porcentagem de dados faltantes iremos utilizar a seguinte linha: `data.isnull().sum()`

Até então, temos a quantidade de dados faltantes. Agora, iremos dividir essas quantidades pelo total de dados no nosso conjunto: "data.shape", índice 0, ou seja, "[0]" e "* 100", para termos a ideia de porcentagem no conjunto de dados.

Ao executar a linha, como as colunas possuem apenas um dado faltante o resultado foi similar

para todas elas. Tivemos 1,69% de dados faltantes, ou seja, em qualquer uma das duas abordagens ainda é seguro utilizar a imputação de dados não se faz necessário remover dado algum.

Então, temos essas duas abordagens: a partir de 25% de dados faltantes, eliminamos a coluna e uma abordagem mais cética na qual, a partir de 10% de dados faltantes podemos eliminar a coluna. Neste caso, nenhuma das duas vai ser necessária.

Podemos, para eliminar a coluna simplesmente pedir as colunas que não gostaríamos de eliminar executar uma consulta utilizando, apenas, as colunas que não gostaríamos de eliminar.

Vamos supor que a massa teria a quantidade de dados faltantes suficiente para ser eliminada.

Então, eliminando a massa, poderíamos fazer a seguinte linha: "data = data[" e passaremos uma lista com as colunas que gostaríamos de manter no caso, todas as outras à exceção de massa. "[fruit_lable ,". O próximo elemento seria outra string: "'fruit_name'," o próximo elemento: "'fruit_subtype'" ", a string "'width'", que seria a largura o próximo elemento da lista: a string "'height'", que seria altura ", e, por fim, a última string: "'color_score'".

Dessa maneira, temos que a nossa variável "data" irá receber todas as outras colunas, com exceção de massa.

Temos que, ao imprimir a linha "data" após executar a linha anterior teremos todas as colunas,

com exceção da massa.

Desse jeito, teremos removido uma coluna. Podemos utilizar esta técnica para eliminar uma coluna que não tenha dados suficientes.

Até mais!