

Transformando a escala dos dados

Olá! Neste vídeo, iremos efetuar uma técnica de pré-processamento com a qual iremos alterar a escala dos dados.

A escala dos dados é, utilizando palavras simples o intervalo ao qual os dados estão abrangendo.

No caso, a massa dos dados de frutas no conjunto de dados que estamos utilizando pode ir de 80, ou mesmo um pouco menos, até 300 unidades de massa, então, temos um intervalo bem grande.

Quanto às cores, são valores entre 0 e 1, ou seja, elas possuem escalas diferentes suas ordens de grandeza são diferentes.

E, por isso, esta diferença na ordem de grandeza pode levar alguns algoritmos de aprendizado de máquina ou algumas análises a darem resultados errôneos.

Por exemplo, uma vez que a massa tenha uma diferença muito grande, ela pode ter uma importância maior para o algoritmo sendo que gostaríamos que os dados tivessem, de maneira geral, importâncias iguais. Então, para aprender esta técnica, nós iremos, primeiramente, ler o nosso conjunto de dados, aplicando os valores faltantes, indicando os valores faltantes, iremos imputar os dados faltantes utilizando a média dessa maneira, as colunas numéricas que são as quais estamos interessados para este pré-processamento serão aplicadas à média, e iremos fazer uma seleção apenas das colunas numéricas uma vez que estamos preocupados apenas com elas neste momento.

Nosso conjunto de dados será calculado da seguinte maneira: em uma célula, na primeira linha, teremos: `data = pd.read_table("fruit_data_with_colors_miss.txt", na_values=[.,?])`.

txt é o nome do arquivo, vírgula após essa string "na_values=" lista com dois elementos: uma string com ponto final, e outra string com ponto de interrogação, ou seja, na "read_table", temos dois argumentos: o nome do arquivo e uma lista de valores dentro desse arquivo que representam dados faltantes.

Na segunda linha, temos: `data = data.fillna(data.mean())` para garantir a imputação dos dados

dos valores numéricos com a média.

E, na última linha, iremos efetuar apenas a seleção das colunas que possuam dados numéricos, então: `"data = data["` e passa-se uma lista com quatro strings: `"'mass', 'width', 'hieght', 'color_score']"`.

Estamos passando a lista, entre colchetes das colunas numéricas.

Dessa maneira, teremos carregado os dados e selecionado apenas as colunas numéricas executando esta célula e a célula seguinte apenas com a variável `"data"`, teremos o nosso conjunto de dados apenas com as colunas numéricas.

Ao aplicar um `"describe"`: `"data.describe()"`, teremos as informações estatísticas do nosso conjunto de dados.

E podemos perceber que tanto a média quanto o desvio padrão assim como os valores mínimos

e máximos dos elementos têm valores bem distintos eles possuem informações estatísticas bem distintas, ou seja, as nossas escalas são bem diferentes.

Então, teremos que, de alguma forma, trabalhar com alguma técnica para efetuar a transformação desses dados de acordo com uma nova escala.

A técnica que será utilizada é a seguinte: para cada coluna, iremos capturar o valor que queremos transformar. Então, estou colocando esta fórmula em um comentário que seria o valor que queremos transformar menos o valor mínimo da coluna dividido pelo valor máximo da coluna, menos o valor mínimo da coluna. Esse vai ser o pré-processamento.

Imagine uma coluna que tenha como valor mínimo `"12"` e o valor máximo `"59"`, e queremos transformar um de seus elementos para a escala entre 0 e 1, ou seja, queremos tornar todas as colunas entre 0 e 1, e utilizaremos esta fórmula para cada elemento de cada coluna.

Então, imagine uma coluna que tenha um valor `"25"`, então eu subtraio ele do mínimo, que seria `"12"`, fica entre parênteses essa subtração, dividido pelo número máximo, `"59"` menos `"12"`.

Temos um valor que está na casa das dezenas e que, ao aplicar esta divisão: `"(25-12) / (59-12)"`, teremos: 0.276595 e alguns outros valores, ou seja, `"0.27"`. O nosso valor `"25"` virou `"0.27"` na nossa nova escala. Essa escala vai de 0 a 1.

Se aplicarmos o `"59"` nesta fórmula então, seria o valor: `"59"` menos o mínimo, que é `"12"` dividido por `"59"`, novamente, menos `"12"`.

Esta divisão irá ser igual a `"1"` uma vez que o numerador e o denominador são iguais.

Se utilizarmos o valor mínimo, "12", o numerador será "0" porque o valor "12", menos o mínimo, que seria o próprio "12" seria "0", que dividido por qualquer valor, seria "0". Só devemos tomar cuidado para o caso de uma coluna cujos valores são todos iguais.

Uma coluna com valores todos iguais não tem informação suficiente uma vez que ela não mostra diferença entre nenhum de seus elementos então ela deve ser descartada.

E se formos aplicar esta técnica em uma coluna desse tipo, o valor máximo menos o valor mínimo, se eles forem iguais, são "0", e o nosso denominador seria "0", e teríamos uma divisão por "0" algo que não gostaríamos de ter.

Então, para aplicar essa técnica a cada uma das colunas iremos utilizar uma função do Sci-kit Learn que já faz isso de uma maneira bem fácil e bem prática de modo que não precisamos

nos preocupar com essa fórmula. Iremos importar a biblioteca que faz essa função.

Podemos utilizar "from", para dizer "a partir de uma biblioteca". Ou seja, na nossa linha, teremos: `from sklearn.preprocessing import MinMaxScaler`.

Ao executarmos esta célula teremos importado um "MinMaxScaler" que é uma classe que efetua a transformação dos dados.

Então, iremos, na próxima coluna, implementar essa classe e construir um objeto, utilizando: "mm", que é a variável que armazenará o objeto "MinMaxScaler" "`= MinMaxScaler`" escrito da mesma forma da linha anterior a qual utilizamos para importar esse objeto, essa classe e, ao final, "()": "`mm = MinMaxScaler()`". E executamos esta célula.

Na próxima célula, iremos utilizar: "`mm.fit`". Esta função, "`fit`", irá nos acompanhar durante todo este curso uma vez que ela é muito utilizada no aprendizado de máquina.

Então: "`mm.fit(data)`", ou seja, estamos passando o nosso conjunto de dados para a função "`fit`"

do "MinMaxScaler": "`mm.fit(data)`".

Esta função "`fit`", ao executarmos esta coluna, irá construir para cada coluna do conjunto de dados "`data`" o máximo e o mínimo deste conjunto de dados.

Dessa maneira, a função "`mm`", o objeto "`mm`" terá armazenado os valores máximo e mínimo que é o importante para efetuarmos a transformação dos dados.

Então, ao aplicarmos esse "`mm`", teremos esse armazenamento.

Agora, precisamos retornar para o nosso conjunto de dados os dados transformados. Como poderemos fazer isso? Poderemos utilizar a função "transform" do "mm".

Confira essa transformação a seguir.

Na próxima linha, iremos utilizar a variável: "data_escala", para armazenarmos os valores escalados, "= mm.transform" transforme, que em inglês é "transform" "(data)".

Dessa maneira, já dissemos as colunas que iremos utilizar e os valores máximo e mínimo e, agora, iremos transformar o conjunto de dados de acordo com os valores armazenados.

No caso, estamos utilizando o mesmo conjunto de dados "data" e iremos armazenar isso na variável "data_escala".

Dessa maneira, ao executarmos o nosso "data_escala" iremos ter nosso conjunto de dados

entre 0 e 1 iremos ter escalado todos os dados de modo que, agora, eles tenham valores entre 0 e 1.

Assim, executamos o pré-processamento para transformar todos os dados em uma única escala.

Portanto, não teremos problemas com alguns algoritmos de aprendizado de máquina que podem se valer da escala dos dados.

Obrigado, e até o próximo vídeo!