

Encontrando outliers

Olá! Neste último vídeo da aula de pré-processamento, iremos encontrar outliers.

O que é um outlier? É o nome de um elemento que possui, em uma de suas características, algo que está fora do padrão. Elementos fora do padrão são prejudiciais aos algoritmos de aprendizado de máquina uma vez que eles são coisas que não acontecem normalmente e um aprendizado de máquina é usado para aprender padrões.

Então, uma boa prática é eliminar esses elementos que estejam fora dos padrões. Podemos utilizar o nosso conjunto de dados que viemos utilizando durante toda esta aula que é o conjunto de dados de frutas com dados faltantes e imputando os dados faltantes com a média.

Dessa maneira, teremos as seguintes linhas: `data = pd.read_table("fruit_data_with_colors_miss.txt", na_values=)` a lista dos elementos que representam valores faltantes que seriam, dentro dessa lista, um ponto final, uma string com: `[".", "?"]`. Ao finalizar essa lista, fechamos o parêntese de `read_table()`.

Na linha seguinte, podemos usar: `data = data.fillna()` que é a função que utilizamos para imputar dados, `(data.mean())` e fecha parênteses novamente, `)`, o do `fillna()`. Ao aplicar essas duas linhas, temos o nosso conjunto de dados carregado novamente.

Primeiramente, iremos utilizar para encontrar os padrões ou o que está fora de padrão, apenas um tipo de fruta: iremos utilizar as maçãs, que são as frutas mais numerosas e, portanto, podemos extrair algumas informações a partir delas.

Para isso, iremos utilizar na próxima linha, na próxima célula a seguinte variável: maçãs, ou melhor, "macas", pois não há como escrever com cedilha, `"= data[data]['fruit_name']"`. Ao fechar o primeiro colchete, utilizamos `"=="` e a string: `"apple"`, que seriam as maçãs, e fecha-se o colchete, `"]`.

Dessa maneira, a variável "macas" só terá as frutas que são referenciadas como maçãs. Então, nós podemos verificar melhor os outliers porque trabalhamos com um só subtipo do nosso conjunto de dados só uma porção do conjunto de dados que deveria ter um padrão bem definido.

Então, primeiramente, iremos aplicar um `"describe"` na variável "macas": `macas.describe()`. E teremos as informações sobre o conjunto de dados de maçãs: média, seu padrão, valores mínimo e máximo e os quartis: `"25%", "50%" e "75%"`.

Iremos utilizar, primeiramente, a técnica de encontrar outliers a partir do desvio padrão.

Então, vamos armazenar essa descrição do "describe" em uma variável.

Vamos utilizar a variável "est", de estatística =macas.describe().

Dessa maneira, iremos armazenar as estatísticas da maçã. Mas, para facilitar o cálculo, iremos, primeiro, observar a nossa coluna de massa.

Após a maçã, entre "macas" e o ponto que antecede o "describe", iremos colocar entre colchetes a string "mass": "[mass]".

Nossa linha ficou: est=macas[mass].describe(). Dessa maneira, teremos armazenadas as estatísticas da coluna de massa.

Vamos observar essa coluna de massa.

Iremos utilizar a seguinte técnica para verificar se as nossas maçãs possuem outliers na sua massa se existem massas maiores ou menores.

Então, iremos utilizar o seguinte, a seguinte linha: "macas[" e iremos efetuar a seguinte condição: "macas['mass']" a string massa, no caso "mass" "> est" que é a nossa variável com as estatísticas de massa "[" e iremos utilizar a string "'mean'", de média "]" + (est", novamente "["std']") utilizamos o asterisco, "*", para multiplicar e "2", para multiplicar por 2, ")"]".

Essa fórmula é um pouco complexa, mas ela quer dizer o seguinte: queremos as maçãs as quais a massa seja maior que a média da coluna de massa das maçãs mais duas vezes o desvio padrão da coluna de massa das maçãs.

O que isso quer dizer? O desvio padrão é a medida que mensura, em média o quanto os meus valores estão variando em relação à média, ou seja, é uma média do quanto eles se afastam da média checando o quanto todos os valores estão se afastando da média.

Estamos verificando o seguinte: as maçãs cujas massas são maiores do que a média mais duas vezes o desvio padrão, estão bem distantes do padrão, ou seja, daquilo que está circulando a média dos valores.

As maçãs que forem retornadas por esse comando devem consideradas outliers.

Ao executar esta linha, teremos uma maçã com massa "192" que é considerada um outlier, ou seja, temos uma maçã que é um outlier para cima consideramos "para cima", por que é acima da média.

Podemos verificar, também, invertendo alguns sinais as maçãs que são outliers para baixo da média.

Então, podemos utilizar a linha: `macas[(macas[mass]<est[mean]-(est[std])*2)]` na linha anterior, era maior que, ">" e utilizamos a coluna "std" do desvio padrão.

Ou seja, nesta condição, nós queremos ver as massas que sejam menores que a média menos duas vezes o desvio padrão.

É a mesma ideia, porém, vendo os outliers para baixo da média. Entendemos, também que uma maçã possui massa "140". Esta massa "140" é pequena em relação à média.

Nós podemos verificar a massa das maçãs utilizando: `est[mean]`.

A média é "165". O desvio padrão, substituindo `"mean"` por `"std"` é "11", logo, em média, as massas das frutas se afastam em 11 unidades da média. Então, o que estiver duas vezes

do desvio padrão para cima da média ou duas vezes do desvio padrão para baixo da média, é um outlier.

E podemos utilizar essa técnica para todas as colunas, para verificar quais são aquelas que estão fora dos padrões.

Óbvio que esse `"* 2"` pode ser alterado podemos utilizar `"* 3"`, se quisermos algo mais rígido somente o que estiver três vezes acima do desvio padrão ou utilizamos uma vez o desvio padrão se quisermos pegar muitos valores com desvio padrão e sermos bem próximos da média.

Mas, o normal é utilizarmos duas vezes o desvio padrão.

Com isso, encerramos esta aula de pré-processamento de dados utilizando Python tendo visto algumas abordagens para pré-processamento como imputação de dados, pré-processamento de escala transformação de escala, exclusão de colunas e eliminação de outliers.

Muito obrigado por ter assistido a esta aula e até a próxima!