

Introdução ao KNN

Olá!

Nesta aula, vocês irão conhecer o k-Nearest Neighbors, ou KNN, um dos modelos de aprendizado de máquina que traduzido seu nome do inglês significa os “k”s vizinhos mais próximos.

É um modelo muito intuitivo, pois se vale da ideia simples de classificar elementos ou executar a regressão de alguns elementos a partir da distância entre eles.

Imagine que você precise desenvolver um sistema que precise calcular a semelhança entre elementos. O seu resultado é a partir da semelhança. E essa semelhança pode ser calculada a partir de uma distância. Então, neste caso, o modelo de KNN aparece como uma boa alternativa pois resolve facilmente esse problema uma vez que as métricas de distância conseguem calcular bem a similaridade entre dois indivíduos.

Interessante, não é?

Como o KNN possui uma intuição simples a matemática por trás dele também é fácil de compreender.

Nós iremos entender como esta distância é calculada usando a métrica da distância euclidiana. Em seguida, aprenderemos a implementar o KNN para classificação e para regressão usando a biblioteca do Sklearn. Também teremos uma compreensão geral de como este modelo funciona a partir da apresentação de exemplos da execução dele. Por fim, aprenderemos a avaliá-lo seguindo a métrica de acurácia e alterando alguns parâmetros, como a quantidade de vizinhos pesquisada.

Então, no decorrer desse curso você irá aprender a utilizar o KNN para efetuar classificação e/ou regressão em cima de um conjunto de elementos.

Mas antes você precisa compreender como calcular a distância euclidiana que é uma das métricas de distância mais utilizadas para esse propósito.

Vamos lá?

A distância euclidiana é aprendida por muitos durante o ensino médio. Também aprendemos e conhecemos o teorema de Pitágoras aquele que diz que, a soma dos catetos ao quadrado é igual a hipotenusa ao quadrado de um triângulo retângulo. Esta fórmula utilizada no teorema de Pitágoras é exatamente igual a fórmula da distância euclidiana.

Para tornar tudo um pouco mais claro, irei mostrar um exemplo entre dois números quaisquer.

Se quisermos mensurar a distância entre dois números iremos tomar como exemplo, os números 2 e 5.

A distância entre os números 2 e 5 é a subtração entre eles, porém essa subtração tem que ser efetuada com um certo cuidado, pois a ordem na qual iremos subtrair não deve fazer diferença no resultado. Logo, se pegarmos primeiro o ponto 5 e subtrairmos o ponto 2 teremos a distância igual a 3.

Mas, no caso contrário, se utilizarmos primeiro o ponto 2 e formos subtrair o ponto 5, teremos uma distância negativa e distâncias negativas não são interessantes até porque não existem. Então, como poderíamos tentar de alguma maneira transformar essa distância que é negativa em uma distância positiva?

Podemos usar a célula do nosso Jupyter Notebook para efetuar esse cálculo. E também podemos examinar o que está ocorrendo.

No caso, se utilizarmos $2-5$, como estou escrevendo na célula o resultado será: -3.

E isso não é interessante porque não reflete uma distância.

Mas, usando 2-5, porém, elevando essa subtração ao quadrado, iremos utilizar a seguinte conta para elevar ao quadrado no Python: $(2-5)**2$

(2, primeiro elemento -5), que é o segundo elemento.

Os dois asteriscos seguidos significam que vamos efetuar uma exponenciação e o 2, ou seja $(2-5)**2$. E, então, ao executar esta célula teremos o 9 positivo até porque qualquer número negativo elevado ao quadrado, irá se tornar positivo.

Então, $2-5 = -3$ $(-3)^2 = (-3 \times -3) = 9$. Só que o 9 ainda não é a nossa distância final.

Estamos tentando utilizar a distância euclidiana e para completar a distância euclidiana iremos repetir a mesma linha anterior só que iremos tirar a raiz quadrada deste número anterior que é exatamente feita da seguinte maneira: vamos reaproveitar a linha anterior, mas iremos colocá-la entre parênteses e adicionar dois * e (0.5). Ou seja, estamos pegando exatamente o resultado da linha anterior e iremos elevá-la a 0.5.

E elevar por 0.5 é igual a elevar a $1/2$. E elevar a $1/2$, é tirar a sua raiz quadrada.

Logo, com esta linha: $((2-5)**2)**(0.5)$, teremos a subtração dos dois elementos que queremos saber a distância estamos elevando essa subtração ao quadrado e estamos tirando a raiz.

Ou seja, no fim, estamos elevando ao quadrado para eliminar um valor negativo e tirando a raiz para voltar para um número normal.

Então, o resultado desta operação será exatamente igual a 3 uma vez que 2-5 ou 5-2 vão ter distância de 3.

Em termos de distância, a distância entre 5 e 2 não interessa a ordem, é 3.

E utilizando essa fórmula de elevar ao quadrado a subtração e tirar a raiz, temos exatamente o valor positivo da distância.

E, desta maneira, aprendemos a utilizar a distância entre dois pontos que possuem apenas uma coordenada.

Como poderíamos utilizar algo para duas coordenadas?

Vamos imaginar a situação em que temos uma fruta na qual temos a massa da fruta e a sua cor o índice de cor.

Então, queremos efetuar a distância entre dois elementos que possuem duas dimensões, ou seja, possuem duas características diferentes.

Iremos efetuar a mesma técnica anterior para cada um dos atributos diferentes da fruta.

Vamos supor que uma das frutas possui a sua massa 5 e a cor é exatamente igual a 0.75.

Iremos escrever isso em Python como uma lista, e iremos armazenar em uma variável, por exemplo:

```
a=[5,0.75]
```

```
b=[2,0.50]
```

ou seja, estamos representando na variável "a" uma fruta que possui massa=5 e cor 0.75.

E a outra fruta na variável "b" que seria de massa=2 e cor 0.50.

Com isto, como conseguimos mensurar a distância entre essas duas frutas?

A distância entre essas duas frutas é um cálculo bem parecido com o anterior, onde iremos, para cada um dos atributos primeiramente para as massas e depois para as cores utilizar a distância entre dois pontos.

Porém, considerando apenas cada um dos atributos separadamente.

Como faremos isso?

Primeiro, iremos utilizar a mesma distância que vimos anteriormente que seria para separar dois pontos.

Temos o 5 e o 2, ou seja, 5-2, que seria a massa da fruta a menos a massa da fruta b.

Iremos elevar ao quadrado para evitar possíveis números negativos.

Então, elevado ao quadrado: $(5-2)^{**2}$.

E teremos o resultado dessa distância elevado ao quadrado.

E iremos somá-lo com o próximo atributo com a subtração ao quadrado do próximo atributo.

Que seria: $((5-2)^{**2} + (0.75 - 0.50)^{**2})$. Estamos separando as duas dimensões a dimensão da massa e a dimensão da cor e estamos subtraindo elas a massa de uma, menos a massa da outra eleva ao quadrado e soma esse resultado com a massa de uma, menos a massa da outra elevado ao quadrado.

Assim, temos as distâncias entre as duas coordenadas elevadas ao quadrado.

E, por fim, iremos elevar todo o resultado por 0.5.

Dessa forma, a raiz quadrada será efetuada pelas somas das diferenças ao quadrado.

Dessa maneira, o resultado ao executar esta linha seria: $((5-2)^{**2} + (0.75 - 0.50)^{**2})^{**0.5}$.

Ou seja, estamos pegando as duas subtrações ao quadrado somando-as e tirando a raiz. E o resultado será algo em torno de: 3,010398.

Em tela, temos um resultado maior. Mas, como ficou a ideia da distância nessa situação?

Nesta situação, a distância entre os dois pontos sendo cada ponto composto por duas coordenadas nós efetuamos a subtração de cada coordenada entre os pontos elevamos essa subtração ao quadrado e tiramos a raiz quadrada do geral.

Então, esta fórmula da distância entre dois pontos pode ser replicada para quantas coordenadas forem necessárias.

Caso de estarmos trabalhando com dados cada coordenada é uma coluna do nosso dado.

Então, iríamos efetuar a distância entre cada um dos elementos de coluna à coluna elevar ao quadrado esses resultados somar todos e tirar a raiz quadrada destes elementos.

Então, dessa maneira, nós temos a distância entre dois pontos que podem ter quantas dimensões forem necessárias e iremos ter apenas um resultado que seria a distância.

Então, desta maneira, conseguimos calcular a distância entre dois elementos, sendo eles quaisquer tipos de dados que possuam quaisquer números de colunas e podemos mensurar a distância entre dois elementos.

Então, estamos encerrando este vídeo tendo apresentado a distância euclidiana que será determinante para a utilização do nosso método KNN.

No próximo vídeo, iremos apresentar a intuição do KNN para podermos implementá-lo em seguida.

Até lá!